

# DETECÇÃO DE FRAUDE EM CARTÕES

Primeira Apresentação

Gabriel Martins

Guilherme Cappelli

Matheus Avila

Matheus Magalhães

Rafael Chaffin

---

# CRONOGRAMA DAS APRESENTAÇÕES

## APRESENTAÇÃO A1: MODELAGEM

Foco na base científica e estatística:

- Análise e tratamento do Dataset.
- Problemática do Desbalanceamento extremo.
- Análise Exploratória e correlações.
- Discussão e geração de Dados Sintéticos.
- Pipeline de Validação (K-Fold + Otimização).

## APRESENTAÇÃO A2: A PLATAFORMA

Foco na aplicação prática e arquitetura:

- Exibição do Dashboard Interativo.
- Simulação de transações em tempo real.
- Análise cruzada de múltiplos modelos.
- Discussão sobre arquitetura e a Stack de Desenvolvimento escolhida.

# O DATASET E AS FEATURES

Dataset **Credit Card Fraud** com 1.000.000 de transações reais, contendo 7 atributos preditores e 1 variável alvo (fraud = 0 Legítima, 1 Fraude).

| Feature                        | Tipo     | Descrição                                           |
|--------------------------------|----------|-----------------------------------------------------|
| distance_from_home             | Contínua | Distância da transação à residência do cliente (km) |
| distance_from_last_transaction | Contínua | Distância em relação à transação anterior (km)      |
| ratio_to_median_purchase_price | Contínua | Razão entre o valor da compra e o preço mediano     |
| repeat_retailer                | Binária  | Cliente já comprou neste estabelecimento (1=Sim)    |
| used_chip                      | Binária  | Transação com chip físico                           |
| online_order                   | Binária  | Transação online (1=Sim)                            |
| used_pin_number                | Binária  | Uso de senha PIN                                    |

# DISTRIBUIÇÃO DA VARIÁVEL ALVO




- Transações Legítimas (91.26%)
- Fraudes Identificadas (8.74%)

A distribuição ilustra um **desbalanceamento crítico**. As fraudes representam apenas uma pequena minoria do dataset (87.403 ocorrências). Qualquer modelagem direta será enviesada para a classe majoritária, ignorando as anomalias.


# ANÁLISE EXPLORATÓRIA (EDA)

Comparação da proporção de ocorrências nas features binárias entre as duas classes.



**Insight:** Fraudes ocorrem quase exclusivamente online e o uso de PIN é um fortíssimo indicativo de legitimidade (quase inexistente nos casos de fraude).

# ANÁLISE EXPLORATÓRIA (EDA)



# A PROBLEMÁTICA DA ACURÁCIA

>93%

Acurácia Enganosa

## A ARMADILHA DO MODELO CEGO

Em um problema tão desbalanceado, se construirmos um modelo "ingênuo" que preveja **todas** as transações como "Legítimas", ele acertará aproximadamente 93% das vezes. Apesar da alta acurácia, ele teria pouca capacidade de encontrar fraudes. Por isso, focamos no **F1-Score**, **Recall** e **AUC-ROC**.

Quando não usamos balanceamento dos dados, Recall varia de 30% - 60% ; Precisão varia de 74% - 89% ; F1-Score varia de 50% - 72%.

# O DESAFIO DOS DADOS SINTÉTICOS

Se conseguíssemos criar dados sintéticos perfeitos, já conheceríamos exatamente os padrões que diferenciam uma operação legítima de uma fraude.

Equalizar 50/50 geraria muitos dados artificiais, forçando o modelo a aprender padrões irreais. O balanceamento deve mitigar o déficit, não criar uma nova realidade.

# PIPELINE E VALIDAÇÃO

## 1. GERAÇÃO DE DADOS SINTÉTICOS DE FRAUDE

### Selecionando observações de fraude:

Bernoulli: Para features binárias, onde  $\Pr[X=1]$  = Proporção observada no dataset original (conj. de treino).

Gaussiana Multivariada: Para features contínuas, com média e covariância estimadas do dataset original (conj. de treino).

## 2. STRATIFIED K-FOLD (5 SPLITS) - DECIDIR QUANTOS GERAR!

O balanceamento será aplicado apenas nos 4 folds de treino, evitando data leakage. Para cada **n\_sintetico** (\*), treina-se o modelo e os testes são feitos apenas em dados reais.

A partir dos resultados nos 5 folds, calcula-se a média e o desvio-padrão do F1-score, Accuracy, Recall, Precision (\*)

Para cada modelo, seleciona-se o valor de **n\_sintetico** considerando o F1-score médio e seu desvio padrão, buscando alto desempenho e baixa variabilidade entre os folds.

Em caso de valores muito próximos, seleciona-se o que tiver menor desvio-padrão de F1 e melhor equilíbrio entre Precision e Recall.

# MODELOS DE MACHINE LEARNING

## LDA

Linear Discriminant Analysis

Baseia-se na hipótese de que as classes seguem distribuições Gaussianas. Projeta os dados maximizando a separação entre as classes de forma linear e rápida.

## QDA

Quadratic Discriminant Analysis

Expande o LDA permitindo matrizes de covariância distintas por classe, ajustando fronteiras não lineares, essenciais para limites assimétricos.

## Logit

Regressão

Logística

Utiliza a função sigmoide para fornecer a probabilidade de uma transação ser fraude .

## R. Forest

Random Forest Classifier


Árvores de decisão que captura interações complexas não lineares.

# IMPLEMENTAÇÃO

A aplicação terá como objetivo disponibilizar telas para exibir a análise exploratória dos dados, a comparação de desempenho dos diferentes modelos avaliados e permitir a simulação de novas entradas, possibilitando ao usuário observar as previsões produzidas por cada modelo.

## Stack Tecnológica

- **Modelagem:** Python (Scikit-Learn, Pandas, NumPy).
- **Backend:** FastAPI (Python).
- **Frontend:** React.



**Obrigado!**

**DÚVIDAS?**

# PIPELINE E VALIDAÇÃO

## OTIMIZAÇÃO DO N SINTÉTICO

Para definir o multiplicador exato de oversampling, construímos uma pipeline automatizada. Testamos empiricamente divisores de 1.0 a 3.0 aplicados aos dados minoritários usando métodos Gaussianos (Contínuos) e Bernoulli (Binários).

## STRATIFIED K-FOLD (5 SPLITS)

Acoplamos a geração sintética **exclusivamente dentro do loop de treino** do K-Fold. Isso assegura que a métrica F1-Score reflita a verdadeira capacidade de generalização do modelo.