

DETECÇÃO DE FRAUDE EM CARTÕES

Segunda Apresentação

Gabriel Martins

Guilherme Cappelli

Matheus Avila

Matheus Magalhães

Rafael Chaffin

CRONOGRAMA DAS APRESENTAÇÕES

APRESENTAÇÃO A1: MODELAGEM

Foco na base científica e estatística:

- Análise e tratamento do Dataset.
- Problemática do Desbalanceamento extremo.
- Análise Exploratória e correlações.
- Discussão e geração de Dados Sintéticos.
- Pipeline de Validação (K-Fold + Otimização).

APRESENTAÇÃO A2: A PLATAFORMA

Foco na aplicação prática e arquitetura:

- Exibição do Dashboard Interativo.
- Simulação de transações em tempo real.
- Análise cruzada de múltiplos modelos.
- Discussão sobre arquitetura e a Stack de Desenvolvimento escolhida.


RECAPITULANDO O DATASET

Dataset **Credit Card Fraud** do Kaggle com 1.000.000 de transações reais, contendo 7 features e 1 variável alvo

Fraud = 0 : Legítima, 1 : Fraude

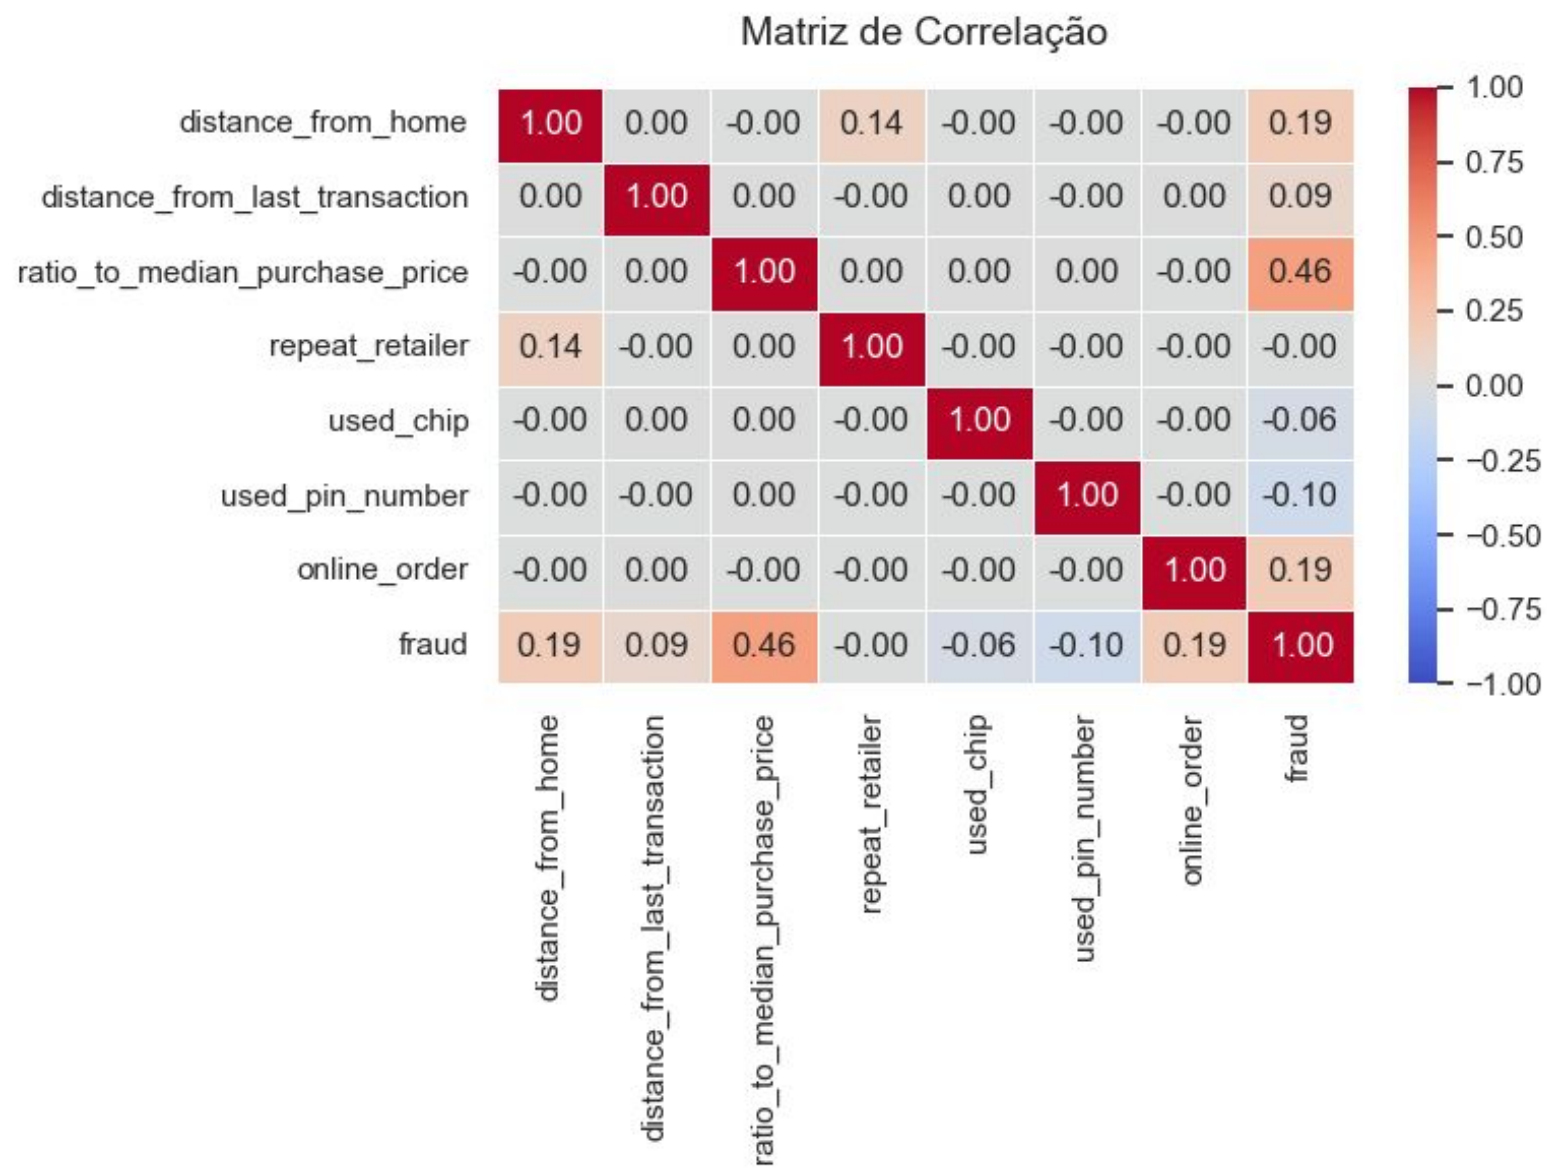
Feature	Tipo	Descrição
distance_from_home	Contínua	Distância da transação à residência do cliente (km)
distance_from_last_transaction	Contínua	Distância em relação à transação anterior (km)
ratio_to_median_purchase_price	Contínua	Razão entre o valor da compra e o preço mediano
repeat_retailer	Binária	Cliente já comprou neste estabelecimento (1=Sim)
used_chip	Binária	Transação com chip físico
online_order	Binária	Transação online (1=Sim)
used_pin_number	Binária	Uso de senha PIN

DISTRIBUIÇÃO DESBALANCEADA




Essa distribuição ilustra um **desbalanceamento crítico**. As **fraudes representam apenas uma pequena minoria** do dataset (87.403 ocorrências). Qualquer modelagem direta será **enviesada para a classe majoritária**, ignorando as anomalias.

ANÁLISE EXPLORATÓRIA (EDA)



ANÁLISE EXPLORATÓRIA (EDA)

Features binárias



💡 **Compra online e uso de PIN apresentam forte separação entre as classes.**

Padrões Comportamentais

01. Vulnerabilidade Digital


A fraude ocorre de forma avassaladora em transações remotas (online), onde a ausência de autenticação física facilita a ação.

02. Barreira PIN

A utilização de senha criptografada (PIN) no ponto de venda inviabiliza quase 100% dos ataques analisados na base.

ANÁLISE EXPLORATÓRIA (EDA)

Histograma | Razão ao Preço Mediano



💡 Fraudes se concentram muito mais em compras várias vezes acima do padrão mediano histórico.

Padrões Comportamentais

01. Explosão no Ticket Médio

Compras legítimas concentram-se em valores habituais (até 2x a mediana). Fraudes disparam e se concentram massivamente quando o valor supera 3x o histórico do cliente.

02. Quebra de Perfil de Gastos

Alterações abruptas e picos repentinos no valor da transação funcionam como o principal gatilho de risco para identificar a ação de fraudadores.

MODELOS DE MACHINE LEARNING

LDA

Linear Discriminant Analysis

Baseia-se na hipótese de que as classes seguem distribuições Gaussianas. Projeta os dados maximizando a separação entre as classes de forma linear e rápida.

QDA

Quadratic Discriminant Analysis

Expand o LDA permitindo matrizes de covariância distintas por classe, ajustando fronteiras não lineares, essenciais para limites assimétricos.

Logit

Regressão

Logística

Utiliza a função sigmoide para fornecer a probabilidade de uma transação ser fraude .

R. Forest

Random Forest Classifier

Árvores de decisão que captura interações complexas não lineares.

PCA + QDA

Principal Component Analysis

Baseia em simplificar dados complexos, reduzindo o número de variáveis e mantendo o máximo de informação original possível.

VALIDAÇÃO CRUZADA COM K-FOLD

Como Funciona?

- O dataset é dividido igualmente em **K partes** (folds).
- Em cada rodada, o modelo treina em **K-1 folds** e é validado no fold restante.
- O processo se repete até que todos os folds tenham sido usados exatamente uma vez como validação.
- Isso reduz a dependência de uma única divisão de treino/teste, gerando uma avaliação muito mais robusta.




No final, calculamos a média das métricas para estimar melhor a capacidade de generalização do modelo.

A RELAÇÃO ENTRE PCA E QDA


O que é o PCA?

O **PCA (Análise de Componentes Principais)** é uma técnica de redução de dimensionalidade. Ele transforma um grande conjunto de variáveis originais em um novo conjunto menor de variáveis ortogonais (descorrelacionadas), chamadas de componentes principais, eliminando redundâncias e ruídos.




Como o PCA facilita o QDA?

O **QDA (Análise Discriminante Quadrática)** exige matrizes de covariância inversíveis. Com alta dimensionalidade, elas se tornam singulares. O PCA resolve esse gargalo ao entregar um espaço reduzido e sem correlação, garantindo estabilidade e eficiência computacional.



O QUE O PCA NOS DIZ



Ponto de Estabilização (Platô): A curva de variância explicada acumulada atinge sua estabilidade máxima a partir do **3º componente principal**.

Retenção de Informação: Com apenas **3 componentes (variáveis)**, o modelo consegue, teoricamente, capturar e explicar **praticamente 100% da variância** de todo o dataset original.

Redução de Dimensionalidade: Comprimiu o espaço original de 7 *features* para um subespaço tridimensional (3D) altamente denso em informação, eliminando ruídos e colinearidade.

Impacto no QDA: Essa compressão para 3 variáveis entrega dados **simplificados e linearmente independentes** para o QDA, garantindo que as matrizes de covariância sejam perfeitamente inversíveis e o treinamento seja rápido e estável.

RESULTADOS DO PCA E QDA (3 COMPONENTES)

ACURÁCIA

92%

PRECISÃO

55%

RECALL

43%

F1-SCORE

48%

POR QUE O PCA PIOROU OS RESULTADOS?

O paradoxo da variância

A Ilusão da Variância

O PCA prioriza componentes que explicam a maior variância. Como **92% do dataset é legítimo**, o algoritmo modela quase exclusivamente o comportamento "normal".

Fraude Tratada como "Ruído"

Padrões fraudulentos são anomalias sutis. A assinatura matemática das fraudes fica na **"cauda" do PCA** (componentes menores), que são sumariamente descartados na redução.

A nossa escolha arquitetural

O Custo da Redução

O PCA estabilizou as matrizes, mas **apagou o sinal** das fraudes. Por isso o *Recall* afundou para **43%**.

Mudança de Rota

Optamos por **NÃO reduzir** as dimensões do dataset.

Próximo Passo

Manter **todas as features** e utilizar modelos (como o **Random Forest**) que conseguem extrair valor de espaços de alta dimensionalidade sem perder o sinal da classe minoritária.

ANÁLISE DA INCORPORAÇÃO DE DADOS SINTÉTICOS (K-FOLDS)

Geração de Dados:

- As observações fraudulentas são extraídas do conjunto de treinamento.
- Em cada rodada, matriz de covariância e as médias são calculada para as **features contínuas**. Em seguida, são geradas assumindo uma **distribuição Gaussiana Multivariada**.
- Já para as **features binárias**, a proporção de cada feature é usada como probabilidade em Bernoulli. (Suposição Features Independentes).
- É possível também explorar **dependência entre as features binárias**: modelando as **combinações observadas no conjunto**, de forma que padrões como (0, 0, 1) possam ser mais frequentes que (1,0,1), preservando um pouco relações entre as variáveis. **Não houve ganho ao assumir dependência! Portanto, usamos Bernoulli.**



Em seguida, analisamos o comportamento das métricas conforme o aumento do número de amostras incorporadas.

MODELO BASELINE

Comparação de Métricas

- Para cada um dos modelos, criamos uma baseline sem **nenhum dado sintético** para avaliarmos as métricas conforme adicionamos amostras sintéticas.
- Espera-se ser possível, individualmente, analisar qual a **melhor opção de número de amostras** para balancear **Precision x Recall**, aumentando o **F1-score**.

Random Forest

- **N^a Estimators: 50**
- **Max Depth: 5**

Logistic Regression

- **C = 1.0**
- **Max Iter: 1000**


LDA

QDA

- **Regularização = 0.0**
(Matriz de Covariância)

Em seguida, analisamos o comportamento das métricas conforme o aumento do número de amostras incorporadas.


MODELO BASELINE



Em seguida, analisamos o comportamento das métricas conforme o aumento do número de amostras incorporadas.


MODELO BASELINE

Baseline - Métricas (média ± desvio padrão)



LDA (Independente)


Qnt Amostras Esperada: 330078




LDA (Dependente)

Baseline Com sintéticos


Accuracy




Precision



Recall



F1 Score



Matriz de Correlação - Features Binárias




QDA (Independente)


Qnt Amostras Esperada: 146701

Baseline Com sintéticos


Accuracy




Precision



Recall




F1 Score




QDA (Dependente)

Baseline Com sintéticos


Accuracy




Precision



Recall



F1 Score




Logistic Regression (Independente)


Qnt Amostras Esperada: 188616

Baseline Com sintéticos


Accuracy




Precision



Recall




F1 Score




Logistic Regression (Dependente)

Baseline Com sintéticos


Accuracy




Precision



Recall







F1 Score



Random Forest (Independente)

Baseline Com sintéticos


Qnt Amostras Esperada: 0




Random Forest (Dependente)

Baseline Com sintéticos


Accuracy




Precision




Recall



F1 Score







MODELO BASELINE - s/ RATIO



Métricas de Avaliação (n_sintético vs Métricas) (Independente)

LDA Logistic Regression QDA Random Forest



SELEÇÃO DE MODELO COM GRID SEARCH + K-FOLD

Combinações Testadas

O espaço de busca do Grid Search avaliou exaustivamente todos os caminhos:

Modelos

LDA, QDA, Regressão Logística e Random Forest.

Hiperparâmetros

Ajustes finos específicos de regularização e profundidade.

Dados Sintéticos

Diferentes volumes (**n_sintetico**) para balanceamento ideal.



Validação em 5 Folds

Garantia de robustez e estabilidade estatística no pipeline:

Stratified K-Fold

Preserva a proporção exata entre transações legítimas e fraudes em cada divisão.

Oversampling Isolado

Geração de dados sintéticos aplicada estritamente no conjunto de treino.

Sem Vazamento

Validação ocorre 100% sobre dados reais, blindando a simulação realística.



Melhor Configuração

O norteador estratégico para a tomada de decisão final:

Critério de Decisão Máximo

A seleção final foi guiada exclusivamente pelo **maior F1-Score médio** obtido na validação cruzada.

Cuidado com a Acurácia

Em datasets altamente desbalanceados, olhar apenas a Acurácia gera conclusões perigosas e excessivamente otimistas.

SELEÇÃO DE MODELO COM GRID SEARCH + K-FOLD

Métricas Avaliadas

F1-Score Médio (5 Folds)

Critério principal de seleção do modelo.

Métricas Acompanhadas

Recall, Precision e Accuracy são monitorados em cada experimento para análise detalhada do desempenho.

Hiperparâmetros de Otimização

LDA — sem hiperparâmetros no grid

QDA — reg_param

Regressão Logística — C, class_weight, max_iter

Random Forest — n_estimators, max_depth, min_samples_leaf, class_weight

Balanceamento sintético — n_sintetico





O Grid Search com Stratified K-Fold comparou modelos, hiperparâmetros e níveis de balanceamento sintético. A melhor configuração foi escolhida pelo maior F1-score médio, adequado para um dataset desbalanceado.


EXEMPLO CURVA AUC-ROC

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$





CURVA AUC-ROC





CURVA AUC-PR X AUC-ROC

ROC vs PR-AUC



CURVA AUC-PR



MODELOS DE MACHINE LEARNING - LDA

Métricas

ROC AUC: 0.97

PR AUC: 0.75

F1-Score: 0.75

Accuracy: 0.95


Precision: 0.80

Recall: 0.71

Parâmetros

n_sintetico: 330078

Matriz de Confusão - LDA



MODELOS DE MACHINE LEARNING - QDA

Métricas

ROC AUC: 0.96

PR AUC: 0.72

F1-Score: 0.82

Accuracy: 0.96

Precision: 0.78


Recall: 0.86

Parâmetros

n_sintetico: 330078

reg_param: 0.0

Matriz de Confusão - QDA



MODELOS DE MACHINE LEARNING - Regressão Logística

Métricas

ROC AUC: 0.97

PR AUC: 0.78

F1-Score: 0.78

Accuracy: 0.96

Precision: 0.80

Recall: 0.76


Parâmetros

n_sintetico: 188616

C: 10.0

max_iter: 1000

Matriz de Confusão - LR



MODELOS DE MACHINE LEARNING - Random Forest

Métricas

ROC AUC: 1.0

PR AUC: 1.0

F1-Score: 1.0

Accuracy: 1.0

Precision: 1.0


Recall: 1.0

Parâmetros

class_weight: balanced

min_samples_leaf: 5

n_estimators: 200



MODELOS DE MACHINE LEARNING - QDA + PCA

Métricas

ROC AUC: 0.96

PR AUC: 0.54

F1-Score: 0.48


Accuracy: 0.91

Precision: 0.55

Recall: 0.43

Parâmetros


Componentes: 3



RANDOM FOREST


Single Decision Tree

Ensemble of trees for more accurate and robust prediction




Random Forest

Prediction from a single decision path




ESTIMATOR

Visualização de uma Árvore Individual da Random Forest (Top 5 Níveis)




SIMULAÇÃO ÁRVORE DE DECISÃO

Árvore de Decisão Substituta (Aproximação da Lógica da Random Forest Inteira)



RELEVÂNCIA DAS FEATURES





IMPLEMENTAÇÃO


A aplicação teve como objetivo disponibilizar telas para exibir a **análise exploratória dos dados**, a **comparação de desempenho** dos diferentes modelos avaliados e permitir a **simulação de novas entradas**, possibilitando ao usuário observar as previsões produzidas por cada modelo.

Stack Tecnológica

- **Modelagem:** Python (Scikit-Learn, Pandas, NumPy).
- **Backend:** FastAPI (Python).
- **Frontend:** React.



DEMONSTRAÇÃO



DISCUSSÃO ÉTICA

O custo do falso positivo

A Prioridade (Recall): Em sistemas antifraude, a métrica mais valorizada é o *Recall*. O objetivo primário do banco é **minimizar os Falsos Negativos** (fraudes que passam despercebidas), protegendo o patrimônio.

O Risco Assumido (Baixa Precisão): Para capturar mais fraudes, o modelo aceita errar mais contra clientes legítimos (**Falsos Positivos**).

O Impacto Real: Matematicamente é apenas um erro na matriz de confusão, mas na vida real significa bloquear o cartão de um cliente honesto durante uma **emergência médica, uma viagem ou uma compra essencial**, gerando constrangimento e danos morais.

Supervisão Humana e Responsabilidade

A Máquina Decide Sozinha? Modelos como o *Random Forest* operam em milissegundos, mas a automação 100% cega transfere o risco do banco para o usuário.

Supervisão Necessária: É **ético e necessário** manter intervenção humana ou atritos positivos (ex: enviar SMS ou notificação perguntando *"Foi você quem fez esta compra?"*) antes de um bloqueio irreversível.

Explicabilidade (Viés Algorítmico): Se o modelo bloquear transações em regiões periféricas por correlação nos dados, o banco precisa conseguir explicar e auditar a decisão, garantindo que o algoritmo não reproduza **discriminação socioeconômica**.



Obrigado!
DÚVIDAS?